

## FINAL PROPOSAL

## 你们这个项目和 LLM Agent 结合的最终方案

定位：不是把主实验“做成 agent”，而是把整个项目升级成一个可解释、可修复、可复测的多语言稳定性审计系统。

## 一句话结论

不要把主实验本身做成自由发挥的 LLM agent。最有价值的方式是做成“双轨制系统”：**轨道 A**：冻结的 benchmark / eval pipeline，保证论文结论干净、可重复；**轨道 B**：agentic diagnosis + repair loop，专门负责发现跨语言失稳的原因、提出修复方案、再做受控复测。这样你们的项目就从“测一测 EN/ZH 会不会漂”升级成一个**面向多语言 LLM / Agent 部署的稳定性审计与修复系统**。

## 1. 为什么这种结合是真有价值的

## 1) 从“发现问题”升级到“解释问题”

你们现在已经能回答 EN 和 ZH prompt 下是否稳定、是否和 human distribution 对齐。但真实价值不只是发现 drift，而是回答：为什么漂、漂在什么层面、这些漂移能不能被修。比如可能的来源包括翻译偏移、文化锚点不同、输出语言约束干扰、同义表达碎裂，以及 prompt framing 不对称。Agent 最适合做的，正是这一层解释与归因。

## 2) 从 benchmark 升级到部署前 QA 工具

这个系统最后不只是服务论文，还可以被包装成：

- 多语言 agent 上线前的稳定性审计工具
- multilingual assistant 的 prompt QA harness
- 不同语言用户下默认决策一致性检查器
- 多 agent 系统中不同语言代理的对齐测试框架

## 3) Agent 恰好适合你们最难的环节

你们 proposal 里真正难的不是算 JSD，而是开放式答案归一化、模糊 case adjudication、failure taxonomy、round-2 repair prompt 生成，以及最终的可解释报告。这些都是 agent 非常擅长的工作，而且能够形成一个完整闭环。

## 2. 最终结构：双轨制系统

| 轨道                              | 目标                                                 | 设计原则                                                                               |
|---------------------------------|----------------------------------------------------|------------------------------------------------------------------------------------|
| 轨道 A                            |                                                    |                                                                                    |
| Frozen Evaluation Lane          | 严谨测量 LLM-human alignment 和 cross-lingual stability | Prompt、decoding、item set、answer-language constraint 全部冻结，不让 agent 改实验条件，保证论文结论可重复。 |
| 轨道 B                            |                                                    |                                                                                    |
| Agentic Diagnosis & Repair Lane | 对异常 item 做归因、修复和复测                                 | 只在主实验跑完之后介入，负责诊断失败类型、生成受控 repair prompt、做 round-2 复测、输出行动建议。                       |

## 3. 轨道 A：冻结的主实验怎么做

主实验回答你们原本的 RQ1 / RQ2，即：

- LLM responses 与 human response distributions 的对齐程度
- 在 matched EN / ZH prompts 下的跨语言稳定性

这一轨必须严格控制：prompt template 冻结、decoding policy 固定、样本预算固定、normalization protocol 尽量前置定义。这样你们最后报告的 JSD、TVD、top-1 match、flip rate 才有方法学说服力。

## 4. 轨道 B：Agentic Diagnosis & Repair Lane

这部分才是最有价值的 agent 结合。它不替代测量，而是在测量之后形成“发现问题 -> 解释问题 -> 生成修复方案 -> 再验证”的闭环。

### 模块 1：Canonicalization Agent

- **任务：**把开放式回答映射到 canonical form。
- **输入：**item、原始回答、输出语言约束、预定义 alias dictionary、简单规则库。
- **输出：**canonical answer、置信度、是否需要人工复核。
- **推荐做法：**Rule-based first -> agent fallback -> human review。不要把全部归一化都交给 agent，否则 reproducibility 会变差。

### 模块 2：Diagnosis Agent

- **任务：**对 EN / ZH 漂移 item 做 failure attribution。
- **输入：**EN prompt、ZH prompt、sample distributions、canonicalized outputs、human distribution、item metadata。
- **输出：**failure tags，例如：
  - translation asymmetry
  - cultural anchor shift

- output-language leakage
- lexical granularity mismatch
- answer-space fragmentation
- over-literal interpretation
- prompt salience imbalance

### 模块 3: Repair Agent

- **任务:** 在不改变 coordination objective、也不泄露 human distribution 的前提下, 生成受控修复策略。
- **允许做的事:**
  - 轻量改写 prompt
  - 强化 answer format 约束
  - 消除 EN / ZH 指令不对称
  - 补一条 task clarification
  - 加入轻量 self-consistency 或 retry framing
- **不允许做的事:**
  - 透露 human top answer 或任何 human distribution 信息
  - 暗示某个具体答案
  - 改变任务本质
  - 通过外部知识 scaffold 去“教模型答对”

## 5. 推荐的完整 workflow

1. **冻结主实验:** 跑 15-20 items、EN/ZH matched prompts、固定 answer language、固定 sampling 预算, 得到分布和主指标。
2. **筛出异常 item:** 例如 EN top-1 不等于 ZH top-1, 或 item-level JSD 超阈值, 或 LLM-human JSD 偏高。
3. **Diagnosis Agent 归因:** 给每个 flagged item 打 failure tags, 并生成证据摘要。
4. **Repair Agent 生成 repair prompt:** 建议限制为有限的修复模板, 而不是无限自由生成。
5. **受控复测:** 只对 flagged items 跑 round-2, 比较修复前后的 JSD、top-1 match、flip rate、human alignment。
6. **自动生成报告:** 输出 item-level case study、failure taxonomy summary、最有效的 repair 类型, 以及无法修复的 item。

## 6. 修复模板建议：只保留三类，避免方法发散

| 修复模板                          | 作用                                                   | 适用失败类型                                                             |
|-------------------------------|------------------------------------------------------|--------------------------------------------------------------------|
| Semantic parity re-pair       | 对齐 EN / ZH 指令语义强度，消除翻译层面的 framing 偏移                 | translation asymmetry、prompt salience imbalance                    |
| Format repair                 | 强制 single-token / noun phrase / answer-only，减少表达粒度碎裂 | answer-space fragmentation、output-language leakage                 |
| Coordination re-minder repair | 轻量强化“你的目标是与另一位回答者匹配”                                 | over-literal interpretation、coordination objective under-specified |

## 7. 论文里最值得升级的研究问题

**RQ3 (Agentic Diagnosis and Controlled Repair)**

对于出现跨语言 focal drift 的 item，一个在严格约束协议下运行的 diagnosis-and-repair agent, 若其既不改变原始 coordination objective, 也不泄露任何 human response information, 是否能够降低 EN / ZH divergence, 并提升与 human response distributions 的对齐程度？

这样你们的文章就不只是 benchmark，而是形成三层贡献：

- **Contribution 1:** human-referenced cross-lingual benchmark
- **Contribution 2:** agentic diagnostic layer，用于解释 drift 来源
- **Contribution 3:** controlled repair loop，用于测试 drift 的可修复性

## 8. 必须避免的四个坑

**坑 1：主实验直接做成 agent**

这样你们最后分不清测到的是模型稳定性，还是 agent 帮它兜底后的稳定性。主实验必须冻结。

**坑 2：归一化全交给 agent**

这会让 reproducibility 变差。要坚持规则优先、agent 兜底、人工抽查的三层结构。

**坑 3：repair 阶段给太多信息**

一旦修复 prompt 暗示了人类更常答什么，实验就不干净了。必须坚持 repair only, no answer hinting。

**坑 4：系统设计过于复杂**

不需要 planner、critic、debater、memory 全家桶。轻量、受控、可解释的架构最好。

## 9. 最终建议的项目表述

**项目名称:** Agent-Augmented Cross-Lingual Coordination Evaluation Framework

**核心设计:** 采用双轨制框架。Frozen Evaluation Track 用于严谨测量 EN / ZH 条件下的 tacit coordination 稳定性与 human alignment; Agentic Diagnosis-and-Repair Track 用于对漂移 item 自动完成答案归一化、失效归因、repair prompt 生成和受控复测。

**实际价值:** 该框架不仅提供 benchmark, 还提供一个面向 multilingual LLM / agent deployment 的稳定性审计工具, 能够把“检测跨语言失稳”进一步推进为“解释失稳原因并评估可修复性”。

## 10. 最终 deliverables

| 模块                            | 交付内容                                                                 |
|-------------------------------|----------------------------------------------------------------------|
| A. Benchmark package          | item wrapper、EN/ZH prompts、human distributions、metrics script        |
| B. Canonicalization module    | alias dictionary、rule set、agent fallback protocol                    |
| C. Diagnosis-and-repair agent | failure taxonomy、repair prompt library、controlled retry protocol     |
| D. Final report / dashboard   | item-level drift cases、bucket analysis、repair gains、unresolved items |

最终判断

最有价值的结合方式不是“让 LLM agent 参与答题”，而是“让 LLM agent 参与测评闭环”。也就是：主实验保持非 agent、可重复；增值部分做 agentic diagnosis + repair。这是最稳、最有研究价值、也最容易讲出实际应用价值的方案。

说明：本 PDF 根据上一轮回答整理成正式文档版，内容保持一致，便于转发、讨论或并入 proposal / 汇报材料。